




FUNDAMENTOS DE **MACHINE LEARNING**

O “BOOM” DA IA



Inteligência
Artificial



Machine
Learning



Deep
Learning

“Pode-se dizer que um programa de computador aprende a partir de uma experiência E com respeito a uma classe de tarefas T e com medida de desempenho P , se seu desempenho P na tarefa T melhora com a experiência E ”

(Mitchell, 1997)



PRINCIPAIS TIPOS DE MACHINE LEARNING



**Aprendizado
Supervisionado**



**Aprendizado
Não-Supervisionado**

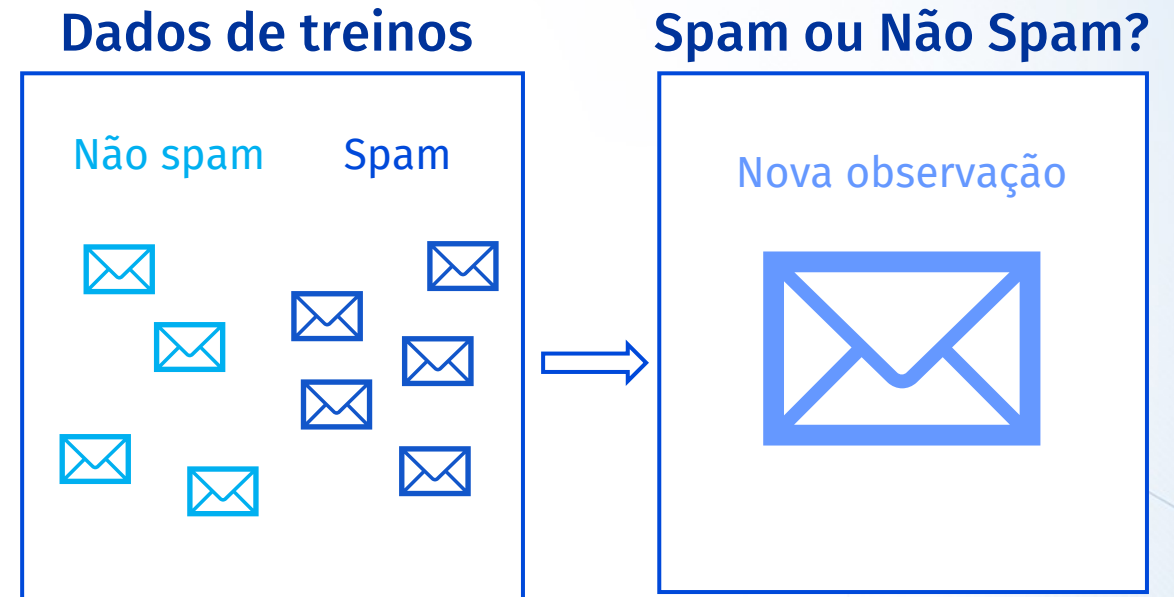


**Aprendizado por
Reforço**

APRENDIZADO SUPERVISIONADO

Os dados possuem rótulo e o principal objetivo é prever ou classificar novas observações.



Exemplo: Classificar um e-mail em spam ou não. O algoritmo é treinado com vários exemplos de e-mails junto com as classes (spam ou não) com o objetivo de classificar novos e-mails.



APRENDIZADO NÃO-SUPERVISIONADO

Os dados não são rotulados e o principal objetivo é identificar padrões nos dados.


Exemplo: Agrupar clientes semelhantes. Em nenhum momento você diz ao algoritmo qual grupo o cliente pertence, o algoritmo terá que encontrar essa conexão sozinho.



APRENDIZADO POR REFORÇO

O sistema de aprendizado aprende sozinho interagindo com o ambiente. **Aprende por tentativa e erro.**


Exemplo: Os “blocos” ao lado estão jogando a partir de uma análise de milhões de jogos e praticando contra si mesmo.




Fonte: Medium



NÃO SUPERVISIONADA X SUPERVISIONADA



No **aprendizado não-supervisionado** não há variáveis de saída, apenas variáveis de entrada. O objetivo é descrever associações e padrões referentes a este conjunto.




No **aprendizado supervisionado**, o objetivo é prever o valor de uma ou mais variáveis de saída (variáveis respostas), baseando-se em uma quantidade de variáveis de entrada (covariáveis).

POMBOS COMO ESPECIALISTAS EM ARTE

Experimento:


- Pombos em uma caixa de Skinner
- São apresentadas pinturas de dois diferentes artistas (e.g. Chagall / Van Gogh)
- Pombos recebem uma recompensa quando apresentados a um particular artista (p. e. Van Gogh)

(Watanabe et al. 1995)




Fonte: HypeScience

VAN GOGH



MARC CHAGALL






Fonte: HypeScience

Pombos foram capazes de discriminar entre Van Gogh e Chagall com acurácia de 95% (quando foram apresentados a pinturas com as quais haviam sido treinados)

Para pinturas dos mesmos artistas que ainda não haviam sido vistas pelos pombos a discriminação ficou em 85%



Fonte: HypeScience

Pombos não memorizam simplesmente as pinturas.

Eles podem extrair e reconhecer padrões.

Eles generalizam a partir do que já viram para fazer previsões.



APRENDIZADO SUPERVISIONADO

Dados




X1, X2

features



**Construção do
Modelo**




$$f(X1, X2) = Y$$

**Novos
Dados**



X1, X2

features




**Use o
modelo**

Predição




REGRESSÃO X CLASSIFICAÇÃO

REGRESSÃO



O objetivo é estimar uma **variável resposta de valor real**, $Y \in \mathbb{R}$, dado um padrão $x \in X$.

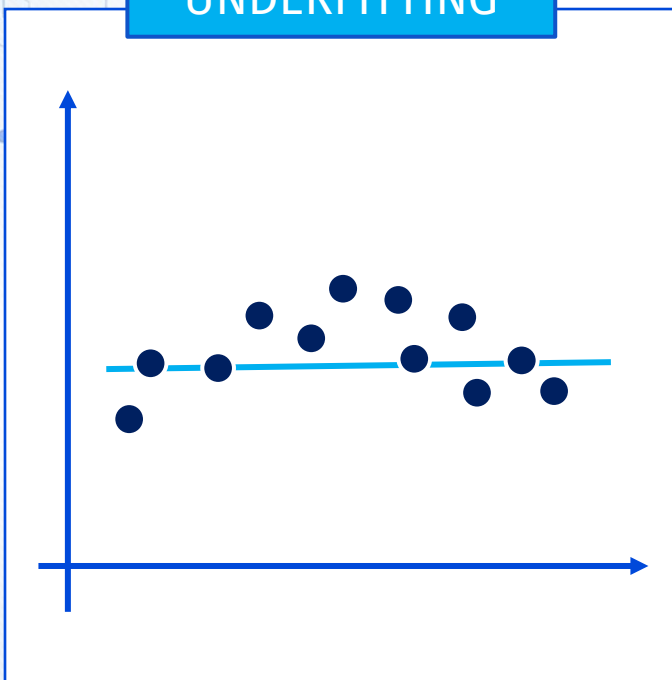
CLASSIFICAÇÃO



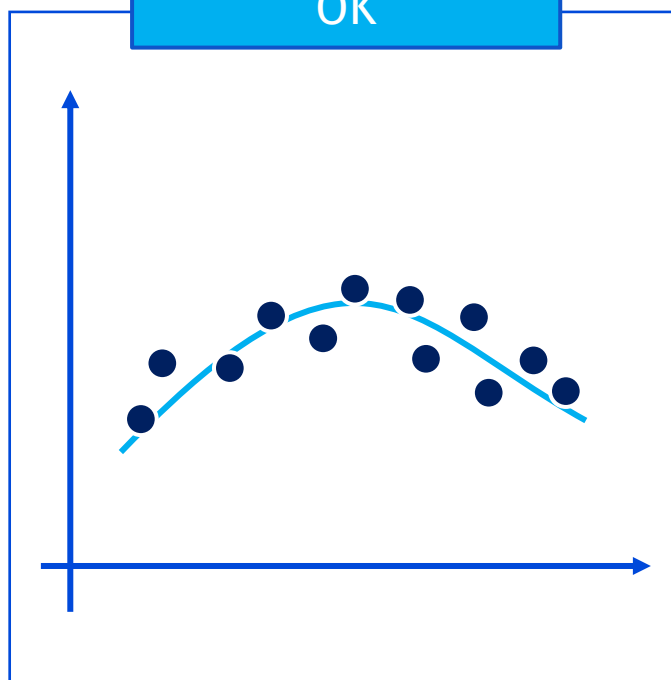
O objetivo é estimar uma **variável resposta de categórica**, isto é, $Y \in \{1, 2, 3, \dots, k\}$, dado um padrão $x \in X$.

EXEMPLO REGRESSÃO


UNDERFITTING



OK



OVERFITTING



EM OUTRAS PALAVRAS



APRENDIZADO SUPERVISIONADO

**UM MODELO PARA
AJUSTAR**

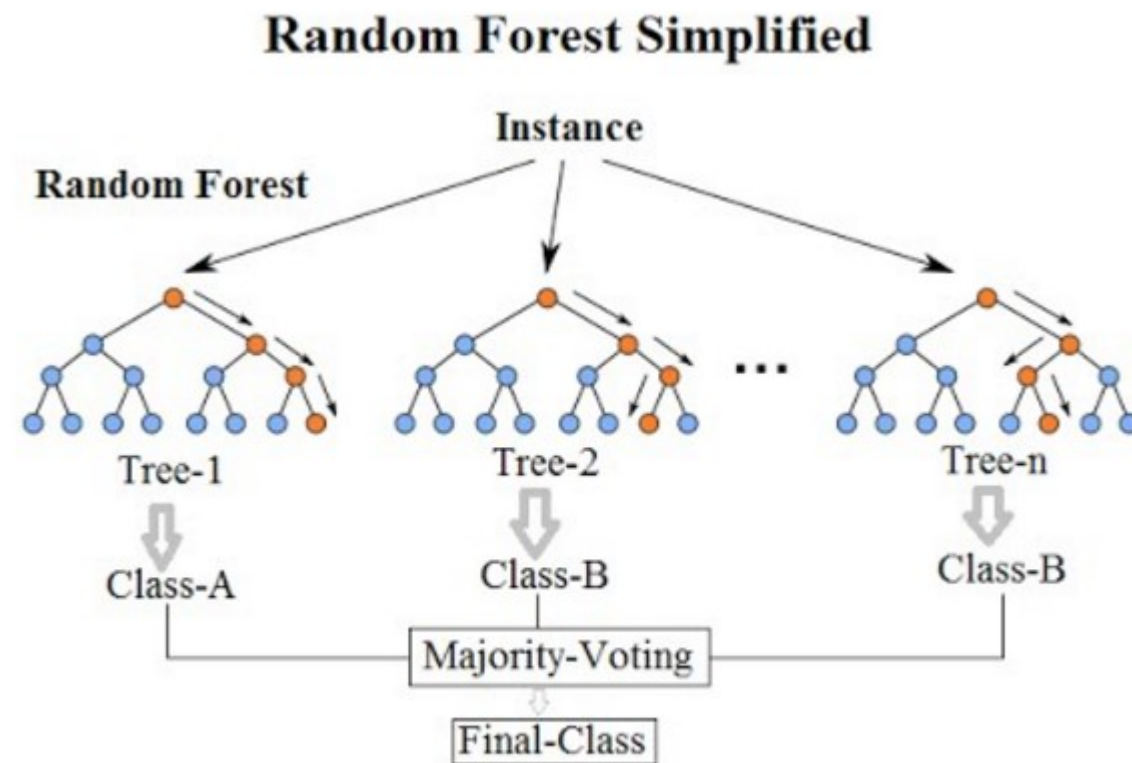

**UMA MÉTRICA PARA
OTIMIZAR**

**UM MÉTODO PARA
VALIDAR**

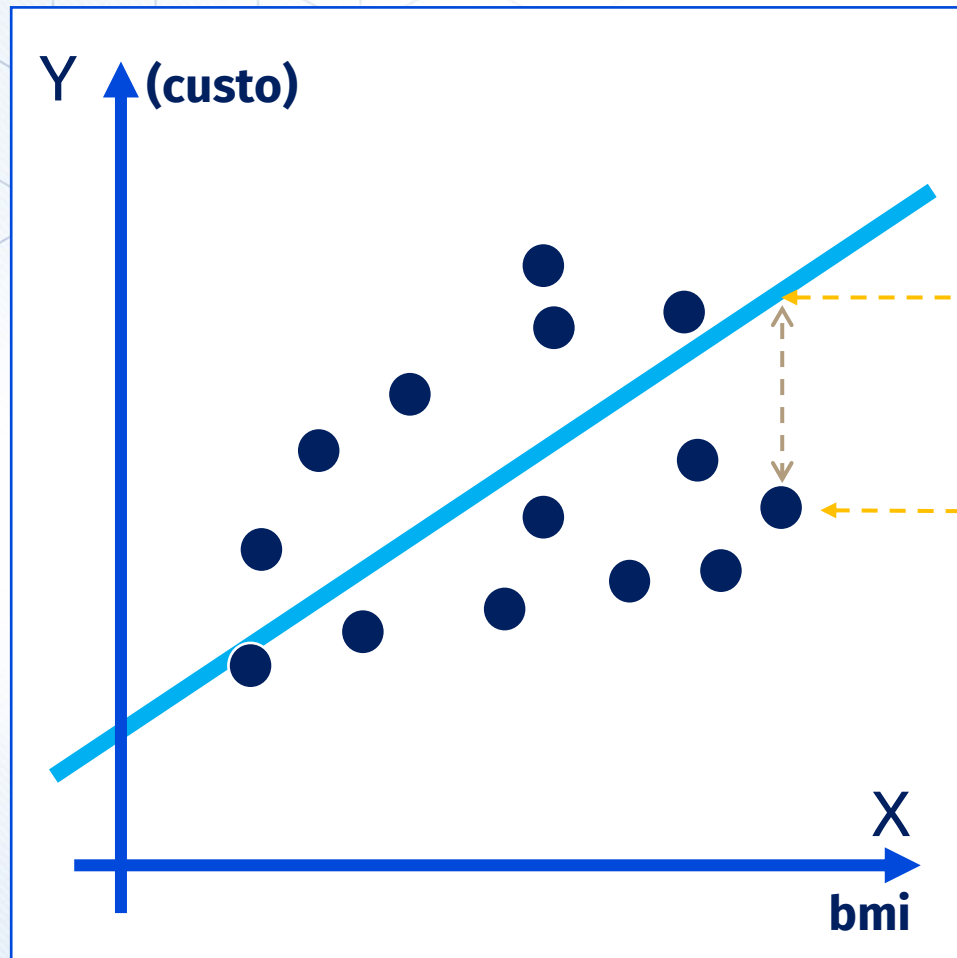


EXEMPLO **REGRESSÃO**

RANDOM FOREST



ERRO QUADRÁTICO MÉDIO



$$MSE = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

VALIDAÇÃO HOLDOUT

CONJUNTO DE DADOS



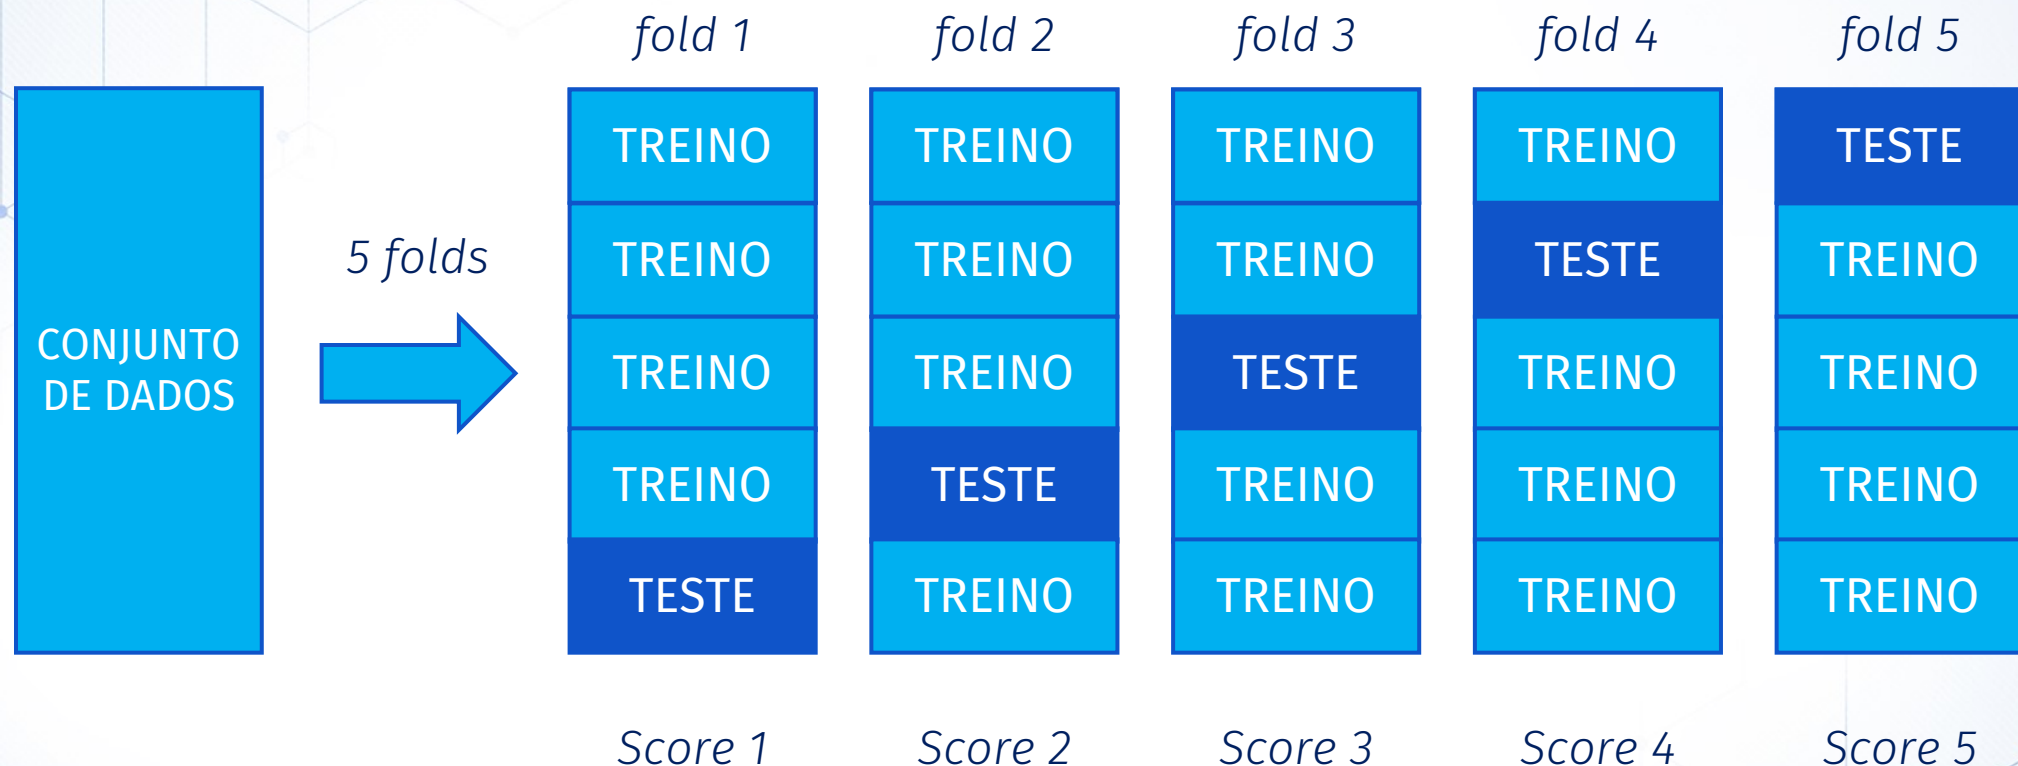
```
graph TD; A[CONJUNTO DE DADOS] --> B[TREINO]; A --> C[TESTE];
```

The diagram illustrates the Holdout Validation process. It starts with a box labeled 'CONJUNTO DE DADOS' (Data Set). Two arrows point downwards from this box to two separate boxes: 'TREINO' (Training) on the left and 'TESTE' (Testing) on the right.

TREINO

TESTE

VALIDAÇÃO CRUZADA K-FOLD



Score Final – Média dos Scores Individuais



HANDS-ON!